

Redes gênicas e a perda de APTX (AOA1): reprogramação do transcriptoma e o módulo das ataxias de reparo de DNA

Pedro Henrique Ramos Prado, MSc.^{1*}

1 Programa de Pós-Graduação em Informática (PPGInf), Universidade Federal do Paraná (UFPR), Curitiba, Paraná, Brasil

* pedroprado@ufpr.br

Abstract

A aprataxina (*APTX*) repara quebras de fita simples de DNA e é a causa da Ataxia com Apraxia Oculomotora tipo 1 (AOA1). Investigamos como a perda de *APTX* reorganiza o transcriptoma de microglia humana (HMC3) a partir do conjunto público GSE245766, num desenho fatorial 2×2 (genótipo $\times$ estímulo imune; $n = 12$), integrando expressão diferencial (DESeq2), co-expressão (WGCNA), co-expressão diferencial (CoDiNA), enriquecimento funcional (GO/KEGG), discretização e modelagem booleana, inferência de rede regulatória (correlação e informação mútua) validada contra STRING, um classificador validado (LOO-CV com seleção de atributos aninhada) e Medicina de Redes (STRINGdb). O efeito do genótipo abrange 1221 genes diferencialmente expressos (DEGs), dominados pelo programa de interferon/antiviral (*IFI44L*, *IFITM1*, *OAS1*, *DDX58*/RIG-I), majoritariamente reprimido no *knockout*. Uma reanálise independente das contagens brutas confirmou os resultados centrais e adicionou três evidências: (i) o “efeito do genótipo” depende do contraste extraído sob o modelo com interação (sobreposição de apenas $\sim 50\%$ entre os contrastes em células não estimuladas e estimuladas); (ii) o mRNA de *APTX* não está reduzido no *knockout* ($\log_2 \text{FC} = +0,21$), indicando perda de *função* e não de expressão; e (iii) o programa de interferon está reprimido especificamente no basal (escore de assinatura de ISG: $p = 5,5 \times 10^{-7}$), coerente com o papel emergente do *APTX* nas vias cGAS-STING / RIG-I-MAVS. O classificador alcançou AUC = 1,00, significativo por teste de permutação ($p = 0,009$). A inferência da rede regulatória por correlação superou a por informação mútua (AUC 0,70 vs 0,59) na validação contra STRING, coerente com a maior estabilidade da correlação sob amostragem limitada. Em conjunto, a perda de *APTX* não reprograma transcricionalmente os genes de reparo em si, mas reconfigura a jusante o programa imune inato.

Author summary

A aprataxina é uma enzima que conserta um tipo específico de dano no DNA; quando ela falta, surge uma doença neurológica hereditária chamada AOA1. Não se sabe bem por que a ausência dessa enzima de reparo afeta o cérebro. Reanalizamos dados públicos de expressão gênica de células de microglia humana, as células de defesa do sistema nervoso, com e sem a aprataxina. Surpreendentemente, os genes clássicos de reparo de DNA quase não mudam de atividade; o que muda é um grande conjunto de genes de defesa antiviral (a resposta de interferon), que fica *desligado* nas células sem aprataxina. Para chegar a essa conclusão, transformamos a expressão dos genes em estados discretos

(ligado/desligado), construímos redes que ligam genes que variam juntos e comparamos duas maneiras de inferir essas redes, medindo o acerto contra uma base de referência de interações conhecidas. Mostramos que, com poucas amostras, um critério simples (correlação) supera um mais sofisticado (informação mútua). Nosso trabalho reforça a ideia de que a aprataxina, além de reparar o DNA, ajuda a regular a resposta imune inata, uma ponte inesperada entre reparo de DNA e imunidade que pode ajudar a entender a AOA1.

O *APTX* (aprataxina) resolve intermediários abortivos 5'-adenilados da ligação de DNA, atuando no reparo de quebras de fita simples (SSBR) em parceria com *XRCC1/XRCC4*. Sua perda causa a AOA1, ataxia recessiva do grupo das ataxias de reparo de DNA (com *SETX*/AOA2, *PNKP*/AOA4, *ATM*/AT). Evidências recentes sugerem que a aprataxina também participa de mecanismos associados à imunidade inata, incluindo vias relacionadas à sinalização cGAS-STING e RIG-I/MAVS [1]. Dessa forma, a investigação de suas interações moleculares e de seus efeitos sobre redes de co-expressão gênica pode contribuir para uma compreensão mais abrangente dos mecanismos envolvidos na AOA1.

Pergunta. Como a perda de *APTX* reorganiza a rede de co-expressão gênica e quais processos (reparo de DNA, resposta imune inata) são afetados? O *APTX* e seus parceiros formam um módulo coerente na rede de interações?

Dados e métodos

A Fig 1 resume o fluxo analítico completo, desde os dados brutos até a validação das redes inferidas.




Fig 1. Fluxograma do *pipeline* analítico. Os blocos em tom avermelhado destacam os métodos de: discretização, modelagem booleana e inferência de rede; o bloco verde indica a etapa de validação por métricas contra a rede de referência STRING.

Os dados de expressão gênica foram obtidos do conjunto público GSE245766 [1],

composto por experimentos de RNA-seq realizados em células de microglia humana da linhagem HMC3. O delineamento experimental seguiu um modelo fatorial 2×2 , considerando os fatores genótipo (*APTX knockout* [APTX-KO] versus tipo selvagem [WT]) e estímulo imune (estimulado [IS] versus não estimulado [NS]), totalizando 12 amostras (3 réplicas biológicas por condição).

As contagens gênicas foram submetidas a controle de qualidade e filtragem de genes com baixa expressão utilizando a função `filterByExpr` do pacote `edgeR`, resultando na retenção de 15 600 genes para as análises subsequentes. Em seguida, os dados foram transformados por estabilização de variância utilizando a função `vst` do pacote `DESeq2`.

A análise de expressão diferencial foi conduzida com o pacote `DESeq2`, utilizando o modelo estatístico $\sim$ genótipo + estímulo + genótipo:estímulo. Foram considerados diferencialmente expressos os genes com valor ajustado de p (p_{adj}) inferior a 0,05 e magnitude absoluta de alteração de expressão superior a $|\log_2 FC| > 1$.

As análises de co-expressão gênica foram realizadas por meio do método *Weighted Gene Co-expression Network Analysis* (WGCNA), utilizando redes do tipo *signed*. Considerando o número reduzido de amostras, a construção da rede teve caráter exploratório. Como não foi observado ajuste satisfatório ao critério de topologia livre de escala (*scale-free topology*), adotou-se o parâmetro $\beta = 18$, conforme recomendação do próprio *framework* para redes *signed*. Alterações na arquitetura das redes de co-expressão entre os grupos APTX-KO e WT foram investigadas utilizando o método CoDiNA (*Co-expression Differential Network Analysis*).

A interpretação funcional dos DEGs foi realizada por análise de enriquecimento utilizando o pacote `clusterProfiler`, considerando termos do Gene Ontology (GO – *Biological Process*) e vias da base KEGG, com correção para múltiplos testes. Para avaliar a capacidade discriminativa entre os grupos KO e WT, foi empregado um modelo *Elastic Net* (`glmnet`) com validação cruzada *leave-one-out* (LOO-CV). A fim de minimizar viés de seleção de atributos, a identificação de DEGs foi repetida independentemente dentro de cada iteração da validação cruzada, conforme recomendado por Ambroise e McLachlan [2]. Por fim, a análise de Medicina de Redes foi conduzida utilizando a base STRINGdb v12.0 para *Homo sapiens* (score ≥ 400), com propriedades topológicas (grau, intermediação, proximidade) calculadas pelo pacote `igraph`.

Reanálise independente. Para verificar a reprodutibilidade e a robustez dos achados, as contagens brutas públicas foram reprocessadas de forma independente (GLM binomial negativo equivalente ao DESeq2; mapeamento Ensembl→símbolo via mygene.info; enriquecimento via Enrichr GO/KEGG; classificador logístico com seleção de atributos aninhada e teste de permutação de rótulos). Essa etapa reteve 15 470 genes após filtragem, praticamente idêntico ao pipeline original.

Discretização e modelagem booleana. Para aplicar os métodos, definiu-se um painel de 30 genes composto pelo módulo das ataxias de reparo de DNA (*APTX*, *TDP1*, *XRCC1*, *XRCC4*, *LIG3*, *LIG4*, *PNKP*, *SETX*, *PARP1*, *ATM*) e por um conjunto de genes da imunidade inata/interferon (*IFI44L*, *OAS1–OAS3*, *ISG15*, *MX1/MX2*, *RSAD2*, *IFIT1/IFIT3*, *STAT1/STAT2*, *IRF7*, *DDX58/RIG-I*, entre outros). Os perfis de *log*-CPM foram padronizados por gene (transformação *z-score*) e, em seguida, *quantizados* em duas representações discretas: (i) *quantização binária*, atribuindo 1 (superexpresso) quando $z > 0$ e 0 (subexpresso) caso contrário; e (ii) *quantização ternária*, atribuindo +1, 0 ou –1 segundo bandas de $\pm 0,5$ desvio-padrão. A partir da representação binária, definiu-se, por votação majoritária entre as réplicas, um *estado booleano de consenso* para cada genótipo (WT e KO); a diferença entre os dois estados foi quantificada pela *distância de Hamming*, número de genes que alternam entre os

Inferência de rede regulatória e validação. A rede de co-regulação do painel foi inferida por dois critérios de relevância: *correlação de Pearson* (dependência linear par-a-par, $|r|$) e *informação mútua* (dependência estatística geral, estimador de vizinhos mais próximos do *scikit-learn*). Cada par de genes recebeu, assim, um escore de associação. As redes inferidas foram validadas contra uma rede de referência (*gold standard*) construída a partir da base STRING v12.0 (interações com $score \geq 0,4$ entre os genes do painel; 212 arestas de referência dentre 435 pares possíveis). O desempenho foi avaliado com a matriz de confusão e as métricas correspondentes - precisão, *recall* (sensibilidade), *F1*, área sob a curva ROC (AUC) e área sob a curva precisão-*recall* (AUPR) - , comparando os dois métodos entre si e contra um classificador aleatório (AUPR igual à prevalência de arestas). Para as métricas pontuais, adotou-se como limiar a seleção das k arestas de maior escore, com k igual ao número de arestas de referência.

Resultados

80

Expressão diferencial (DESeq2)

81

Foram identificados 1221 DEGs entre as condições APTX-KO e WT (Tabela 1). Os genes mais significativamente alterados incluem *IFI44L*, *IFITM1*, *OAS1*, *IFI6*, *IFIT1*, *USP18*, *BST2* e *DDX58* (RIG-I) (Tabela 2). Muitos desses genes estão descritos na literatura como participantes de respostas mediadas por interferon e mecanismos de defesa antiviral, sugerindo uma modulação de processos relacionados à imunidade inata, hipótese posteriormente explorada pelas análises de enriquecimento funcional.

Tabela 1. Número de genes diferencialmente expressos por contraste ($p_{\text{adj}} < 0,05$ e $|\log_2 \text{FC}| > 1$).

Contraste	DEGs	Up	Down
Genótipo (KO vs WT)	1221	554	667
Estímulo (IS vs NS)	1291	936	355
Interação genótipo $\times$ estímulo	209	82	127

Tabela 2. Top 12 DEGs do efeito do genótipo (KO vs WT). Predomina o programa interferon/antiviral. p_{adj} abaixo do limite de precisão numérica indicado como $< 2,2 \times 10^{-16}$.

Gene	$\log_2 \text{FC}$	p_{adj}
<i>IFI44L</i>	-4,84	$< 2,2 \times 10^{-16}$
<i>IFITM1</i>	-3,42	$< 2,2 \times 10^{-16}$
<i>GOLGA4</i>	+3,29	$< 2,2 \times 10^{-16}$
<i>BST2</i>	-3,25	$< 2,2 \times 10^{-16}$
<i>CDH13</i>	+3,08	$< 2,2 \times 10^{-16}$
<i>OAS1</i>	-2,78	$< 2,2 \times 10^{-16}$
<i>RIGI</i>	-2,42	$< 2,2 \times 10^{-16}$
<i>IFI44</i>	-2,40	$< 2,2 \times 10^{-16}$
<i>PSG1</i>	+2,36	$< 2,2 \times 10^{-16}$
<i>USP18</i>	-2,31	$< 2,2 \times 10^{-16}$
<i>IFI6</i>	-2,30	$< 2,2 \times 10^{-16}$
<i>IFIT1</i>	-2,17	$< 2,2 \times 10^{-16}$

O “efeito do genótipo” depende do contraste. No modelo com interação, o coeficiente principal de genótipo testa KO vs WT apenas no nível de referência do estímulo (células não estimuladas, NS). A reanálise extraiu os três contrastes possíveis (Fig 2a): KO-vs-WT em NS (1294 DEGs, reproduzindo o número original), KO-vs-WT em IS (1161 DEGs) e o efeito marginal de genótipo (modelo aditivo; 1252 DEGs). A sobreposição entre as listas em NS e IS é de apenas Jaccard = 0,50 (822 DEGs em comum; 472 exclusivos de NS; 339 exclusivos de IS), indicando que quase metade dos DEGs de genótipo muda conforme o contraste. Portanto, descreve-se o contraste principal como “KO vs WT em células não estimuladas”.

Co-expressão (WGCNA e CoDiNA)

Com $n = 12$ o ajuste *scale-free* é fraco; adotou-se $\beta = 18$. A análise WGCNA identificou oito módulos de co-expressão (Tabela 3). Os módulos *yellow* ($r = -0,98$) e *blue* ($r = 0,96$) apresentaram as correlações mais elevadas com o fator genótipo, enquanto *turquoise* ($r = 0,98$) e *red* ($r = -0,96$) predominaram no fator estímulo. Entre os genes previamente selecionados, apenas *SETX* foi alocado ao módulo *turquoise*, enquanto *TDP1* e *LIG3* foram alocados ao módulo *blue*; *APTX* não foi incluído na rede construída a partir dos 5000 genes mais variáveis, o que pode refletir sua limitada variação transcricional nas condições avaliadas.

A comparação das redes por CoDiNA identificou 1454 nós conservados entre as condições, além de 224 nós com conectividade específica do grupo APTX-KO e 291 nós com conectividade específica do grupo WT, sugerindo alterações nos padrões de conectividade associados à perda de *APTX*.

Tabela 3. Correlação entre *eigengenes* dos módulos e os fatores experimentais. Com $n = 12$, os p -valores são nominais/otimistas e a interpretação deve ser feita em nível de módulo.

Módulo	r_{gen}	p_{gen}	r_{est}	p_{est}
yellow	-0,98	$1,3 \times 10^{-8}$	-0,17	$5,9 \times 10^{-1}$
blue	+0,96	$9,3 \times 10^{-7}$	+0,28	$3,8 \times 10^{-1}$
green	+0,89	$8,7 \times 10^{-5}$	-0,44	$1,5 \times 10^{-1}$
brown	-0,83	$8,5 \times 10^{-4}$	+0,54	$7,2 \times 10^{-2}$
black	-0,60	$3,9 \times 10^{-2}$	-0,76	$3,9 \times 10^{-3}$
red	+0,23	$4,7 \times 10^{-1}$	-0,96	$1,2 \times 10^{-6}$
turquoise	-0,06	$8,6 \times 10^{-1}$	+0,98	$1,1 \times 10^{-8}$
grey	-0,05	$8,7 \times 10^{-1}$	-0,08	$8,1 \times 10^{-1}$

Enriquecimento funcional (GO/KEGG)

As análises de enriquecimento evidenciaram predominância de processos relacionados à resposta antiviral e à imunidade inata. Entre os termos GO (*Biological Process*) mais significativos destacam-se *type I interferon signaling*, *cellular response to type I interferon*, *negative regulation of viral genome replication*, *defense response to virus* e *cytokine-mediated signaling* (todos $p_{\text{adj}} < 10^{-6}$). Entre as vias KEGG canônicas destacam-se *Cytokine-cytokine receptor interaction*, *NF-kappa B signaling pathway*, *NOD-like receptor signaling pathway* e *Influenza A*. A reanálise confirmou essa biologia e evidenciou que a escolha do universo de referência (genoma inteiro versus genes expressos) altera materialmente o número de termos significativos (GO BP: 130 versus 231; KEGG: 20 versus 36), reforçando a importância de declarar explicitamente o universo de *background*.

Assinatura de interferon

Para quantificar o programa antiviral, calculou-se um escore de assinatura de genes estimulados por interferon (ISGs) por amostra (Fig 2b). O programa está fortemente reprimido no KO *especificamente no basal* (NS: WT $-0,26$ vs KO $-1,36$; $p = 5,5 \times 10^{-7}$), enquanto sob estímulo os grupos quase convergem (IS: WT $+0,89$ vs KO $+0,74$; $p = 5,1 \times 10^{-3}$). Esse padrão, redução do tônus basal de sinalização de interferon, é exatamente o esperado se as vias cGAS-STING e RIG-I-MAVS estiverem menos ativas na ausência de *APTX*, e explica por que o teste marginal de genótipo é comparativamente fraco: o efeito é dirigido pela interação (basal), não uniforme entre estímulos.

Classificação (LOO-CV) e teste de permutação

Ambos os modelos (DEGs com seleção aninhada; *eigengenes* do WGCNA) alcançaram desempenho máximo (AUC = 1,00; 12/12 amostras corretamente classificadas). Para avaliar se esse resultado é significativo dado o tamanho amostral, realizou-se um teste de permutação de rótulos (1000 permutações, com todo o pipeline (incluindo a seleção aninhada) refeito em cada permutação; Fig 2c). A distribuição nula centrou-se em AUC = 0,34 (95º percentil = 0,78), com p empírico = 0,009. Assim, AUC = 1,00 é estatisticamente significativo e não um artefato do n pequeno. Ressalva-se, contudo, que o modelo baseado em *eigengenes* do WGCNA permanece sujeito a vazamento de informação, pois os módulos foram derivados usando as 12 amostras simultaneamente; sua interpretação deve ser cautelosa.




Fig 2. Reanálise independente das contagens brutas do GSE245766. **(a)** O número de DEGs do efeito do genótipo depende do contraste extraído sob o modelo com interação; a linha tracejada indica o valor original (1221). **(b)** Escore de assinatura de ISG por grupo: o programa de interferon está reprimido no KO especificamente no basal (NS). **(c)** Distribuição nula do AUC de LOO-CV sob permutação de rótulos; o valor observado (1,00) é significativo ($p = 0,009$).

Discretização e estados booleanos

A quantização ternária dos 30 genes do painel evidenciou um padrão dominado pelo estímulo imune no bloco de genes de interferon, coerente com os resultados de expressão diferencial, e alterações mais discretas no bloco de reparo de DNA (Fig 3a). A partir da representação binária, os estados booleanos de consenso dos genótipos WT e KO diferem em uma *distância de Hamming* de 10/30 genes (Fig 3b): alternam de estado *TDPI1*, *XRCC4*, *LIG3*, *PNKP* e *ATM* (bloco de reparo) e *IFI44L*, *IFI44*, *IFI6*, *BST2* e *IRF7* (bloco imune). Essa análise discreta recupera, de forma simplificada e interpretável, a coexistência de alterações no módulo de reparo e no programa de interferon já observada pelas análises contínuas.




Fig 3. Discretização e modelagem booleana do painel de 30 genes. **(a)** Quantização ternária (z -score por gene): +1 superexpresso (vermelho), 0 neutro (cinza), -1 subexpresso (azul). A linha horizontal separa o módulo de reparo de DNA (topo) do módulo de imunidade inata; a linha vertical tracejada separa amostras não estimuladas (NS) de estimuladas (IS). **(b)** Estado booleano de consenso por genótipo (votação majoritária das réplicas); genes destacados alternam de estado entre WT e KO (distância de Hamming = 10/30).

Inferência de rede regulatória: correlação vs. informação mútua 153

A rede de co-regulação do painel foi inferida por dois critérios, correlação de Pearson e 154
informação mútua, e validada contra a rede de referência STRING (Fig 4; Tabela 4). A 155
correlação apresentou desempenho superior em todas as métricas (AUC = 0,70; AUPR 156
= 0,71; F1 = 0,63) em comparação à informação mútua (AUC = 0,59; AUPR = 0,55; F1 157
= 0,59), ambas acima do classificador aleatório (AUPR = 0,49). Esse resultado é 158
coerente com as propriedades dos métodos discutidas em aula: estimadores de 159
informação mútua requerem mais amostras para estabilizar, ao passo que a correlação 160
linear é robusta em regimes de $M \ll N$ (aqui, apenas $M = 12$ amostras), embora seja 161
incapaz de capturar dependências não lineares ou relações $N:1$. Metodologicamente, 162
isso ilustra o compromisso entre a generalidade do critério de relevância e a estabilidade 163
estatística sob amostragem limitada. 164

Tabela 4. Validação das redes inferidas contra o *gold standard* STRING ($\geq 0,4$; 212 arestas dentre 435 pares). Métricas pontuais no limiar top- k ($k = 212$). Melhor valor por métrica em negrito.

Método	AUC	AUPR	Precisão	Recall	F1
Correlação ($ r $)	0,70	0,71	0,63	0,63	0,63
Informação mútua	0,59	0,55	0,59	0,59	0,59
Aleatório (prevalência)	0,50	0,49	—	—	—

Medicina de Redes (STRINGdb) 165

A rede de interações dos dez genes-semente (Figura 5) mostrou-se significativamente 166
mais conectada que o esperado ao acaso (41 interações observadas *vs.* 2 esperadas; 167
 $p < 10^{-16}$), confirmando que formam um módulo funcional coeso de reparo de DNA. 168




Fig 4. Inferência da rede de co-regulação do painel validada contra STRING. (a) Curvas ROC e (b) curvas precisão-*recall* para os dois critérios de relevância; a linha tracejada indica o classificador aleatório. (c) Métricas de validação no limiar top-*k*. A correlação supera a informação mútua em todas as métricas neste regime de poucas amostras ($M = 12$).

ATM e *PARP1* apresentaram os maiores valores de grau e intermediação, destacando-se como os nós mais conectados do módulo (Tabela 5). O *APTX*, embora com grau relativamente menor, exibiu elevada centralidade de intermediação ($\sim 12\,430$), sugerindo função de conexão entre subconjuntos da rede, padrão compatível com seu papel no reparo de quebras de fita simples (SSBR). Embora nenhum gene-semente tenha ultrapassado $|\log_2 FC| > 1$, cinco genes (*APTX*, *TDP1*, *XRCC1*, *XRCC4* e *LIG3*) apresentaram significância estatística após correção, sugerindo alterações discretas em componentes do módulo de reparo.

Tabela 5. Centralidade dos genes-semente na rede STRING e significância no KO ($p_{\text{adj}} < 0,05$).

Gene	Grau	Intermediação	Signif. KO
<i>ATM</i>	770	55 681	não
<i>PARP1</i>	710	53 233	não
<i>XRCC1</i>	229	5603	sim
<i>LIG3</i>	206	2916	sim
<i>LIG4</i>	200	5541	não
<i>SETX</i>	168	11 825	não
<i>XRCC4</i>	139	3104	sim
<i>APTX</i>	113	12 430	sim
<i>PNKP</i>	107	7003	não
<i>TDP1</i>	88	2061	sim

Discussão

Os resultados sugerem que a perda de *APTX* está associada a alterações mais pronunciadas em programas relacionados à imunidade inata do que na expressão dos genes clássicos de reparo de DNA. Os genes diretamente envolvidos no reparo apresentaram alterações transcricionais discretas, compatível com a função predominantemente enzimática atribuída à aprataxina.

Um achado que merece destaque é que o mRNA de *APTX* não está reduzido no *knockout*, a reanálise confirmou $\log_2 FC = +0,21$ (p_{adj} significativo), reproduzindo o $+0,27$ original. Isso indica que o modelo é um *knockout funcional* (lesão gerando




Fig 5. Módulo de reparo de DNA dos genes-semente na rede STRING. Rede de interações proteína-proteína (STRINGdb, *Homo sapiens*, versão 12.0) dos dez genes-semente das ataxias de reparo. O conjunto exibe enriquecimento significativo de interações (41 observadas *vs.* 2 esperadas ao acaso; $p < 10^{-16}$), evidenciando um módulo funcional coeso. O *APTX* integra-se ao módulo com elevada centralidade de intermediação (Tabela 5), compatível com seu papel de conexão no reparo de quebras de fita simples.

transcrito estável, porém proteína não-funcional), e não um *knockout* de expressão. Portanto, o achado fica descrito como “perda de função de *APTX*”.

Em contraste, foram observadas alterações expressivas em genes e vias associadas à resposta antiviral e à sinalização por interferon, incluindo *DDX58* (RIG-I), *OAS1* e diversos ISGs. Essa tendência foi consistente nas análises de expressão diferencial, enriquecimento funcional, co-expressão diferencial e no escore de assinatura de ISG, apontando para processos de resposta a vírus, sinalização por interferon tipo I e II, NF- κ B e receptores NOD-like. Esses achados são compatíveis com evidências recentes de uma interface funcional entre os mecanismos de reparo de DNA mediados por *APTX* e as vias da imunidade inata (eixos cGAS-STING e RIG-I-MAVS) [1]. Importante: a direção observada é concordante com o estudo de origem, o que confere à presente reanálise o caráter de *validação independente*.

Na análise de redes de interação proteína-proteína, o *APTX* apresentou elevada centralidade de intermediação, sugerindo potencial participação na conexão entre componentes do módulo das ataxias de reparo de DNA, enquanto *ATM* e *PARP1* destacaram-se como os nós mais centrais.

A aplicação dos métodos de discretização, modelagem booleana e inferência de rede regulatória, agregou uma perspectiva complementar às análises contínuas. A representação booleana de consenso resumiu as alterações de estado entre WT e KO (distância de Hamming = 10/30), localizando-as simultaneamente nos blocos de reparo de DNA e de interferon. Na inferência da rede de co-regulação, a comparação entre correlação e informação mútua contra a rede de referência STRING evidenciou a superioridade da correlação neste regime de poucas amostras. Esse achado ilustra uma propriedade metodológica central: critérios de relevância mais gerais, como a informação mútua, capturam dependências não lineares e relações multivariadas, mas exigem maior número de amostras para uma estimativa estável; sob $M \ll N$, a correlação linear, apesar de suas limitações, tende a produzir inferências mais robustas. Trata-se de uma

limitação devido ao tamanho da amostra ($n = 12$), e não ao modelo de informação mútua em si.

Limitações

1. O estudo foi realizado em linhagem celular de microglia humana (HMC3), e não em amostras de pacientes com AOA1; os resultados devem ser interpretados no contexto de um modelo *in vitro*. O reduzido número de amostras ($n = 3$ por condição) confere caráter exploratório às análises de co-expressão.
2. O critério de ajuste à topologia livre de escala não foi plenamente atendido; $\beta = 18$ foi definido por recomendação do *framework* WGCNA para redes *signed*, e não estimado diretamente dos dados.
3. Os modelos de classificação apresentaram AUC = 1,00; embora o teste de permutação confirme a significância, o reduzido tamanho amostral limita a avaliação da capacidade de generalização, e a forte separação entre condições torna a tarefa relativamente simples. Análises dos efeitos de estímulo ou interação podem ser mais informativas.
4. Observou-se discreto aumento da expressão de *APTX* no contraste KO versus WT ($\log_2$ FC = +0,27), possivelmente refletindo a estratégia de geração do *knockout* ou mecanismos compensatórios; a interpretação requer confirmação das características moleculares do modelo original.

Conclusão

A perda de *APTX* está associada predominantemente a alterações em programas transcricionais relacionados à imunidade inata e à sinalização por interferon, enquanto os genes clássicos de reparo de DNA apresentaram alterações mais discretas. Entre os parceiros funcionais de *APTX*, *XRCC1*, *XRCC4*, *LIG3* e *TDP1* apresentaram mudanças estatisticamente significativas, embora de baixa magnitude. As análises de redes indicaram elevada centralidade de intermediação para o *APTX* dentro do módulo das ataxias de reparo de DNA. Em conjunto, os achados são consistentes com a hipótese de uma interface funcional entre mecanismos de reparo de DNA e processos da imunidade inata no contexto da AOA1, fornecendo subsídios para estudos funcionais futuros.

Principais contribuições. O trabalho (i) reproduziu de forma independente, a partir das contagens brutas, os resultados centrais do estudo original; (ii) explicitou que o “efeito do genótipo” depende do contraste sob o modelo com interação e que o *knockout* é funcional, não de expressão; e (iii) aplicou métodos de discretização, modelagem booleana e inferência de rede regulatória, comparando dois critérios de relevância contra uma rede de referência.

Dificuldades encontradas. As principais dificuldades foram: o pequeno tamanho amostral ($n = 12$), que limita a estabilidade de estimadores como a informação mútua e torna correlações otimistas; a dependência do resultado de expressão diferencial em relação ao contraste extraído sob o modelo com interação, exigindo cuidado na interpretação do “efeito de genótipo”; a anomalia aparente do $\log_2$ FC de *APTX* (positivo apesar do *knockout*), esclarecida como perda de função; a ausência do próprio *APTX* em algumas redes de co-expressão; e a escolha de limiares (discretização, *score* STRING, top-*k*) que influenciam as métricas e foram fixados de forma justificada. A

separação perfeita do classificador (AUC = 1,00) exigiu um teste de permutação para demonstrar significância apesar de n pequeno.

Síntese e justificativa. Em síntese, a correlação superou a informação mútua na inferência da rede (AUC 0,70 vs 0,59), o que se justifica pela maior robustez de estimadores lineares sob amostragem limitada, uma propriedade metodológica diretamente ligada ao desempenho observado. O conjunto de análises converge para uma reprogramação a jusante do programa imune inato como assinatura transcricional dominante da perda de *APTX*.

Disponibilidade de código e dados

Os dados de expressão são públicos (GEO, acesso GSE245766). O código completo de reproprocessamento (discretização, modelagem booleana, inferência de rede e validação), os *scripts* de geração de figuras e a fonte L^AT_EX do artigo estão disponíveis no repositório:

<https://github.com/ppufpr/projeto-APTX-AOA1>

Declaração de uso de Inteligência Artificial

Ferramenta utilizada. Assistente de IA generativa.

Como e onde foi utilizada. A ferramenta foi empregada como apoio em três etapas: (i) *revisão crítica e compreensão* das referências bibliográficas e dos conceitos biológicos; (ii) *em scripts R e Python* na escrita e correção de bugs dos scripts; e (iii) *ajustes na formatação* em L^AT_EX.

Todos os resultados numéricos foram computados a partir dos dados reais (GSE245766), verificados por reexecução dos *scripts*.

Prompts utilizados (síntese). As principais solicitações feitas à ferramenta foram, em ordem cronológica:

1. “Preciso de ajuda no entendimento de biologia do papers.”
2. “Análise os bugs e realize a sugestão de correção do script...” (correção e ajustes em problemas de compilação).
3. “Ajude na correção da formatação do documento padrão L^AT_EX com base no template fornecido.”

Referências

1. Madsen HB, Pease LI, Scanlan RL, Akbari M, Rasmussen LJ, Shanley DP, Bohr VA. The DNA repair enzyme, aprataxin, plays a role in innate immune signaling. *Frontiers in Aging Neuroscience*. 2023;15:1290681. doi:10.3389/fnagi.2023.1290681. (Dados: GEO GSE245766.)
2. Ambroise C, McLachlan GJ. Selection bias in gene extraction on the basis of microarray gene-expression data. *Proceedings of the National Academy of Sciences*. 2002;99(10):6562–6566. doi:10.1073/pnas.102102699.

3. Kauffman SA. Metabolic stability and epigenesis in randomly constructed genetic nets. *Journal of Theoretical Biology*. 1969;22(3):437–467. doi:10.1016/0022-5193(69)90015-0.
4. Shmulevich I, Dougherty ER, Kim S, Zhang W. Probabilistic Boolean networks: a rule-based uncertainty model for gene regulatory networks. *Bioinformatics*. 2002;18(2):261–274. doi:10.1093/bioinformatics/18.2.261.
5. Butte AJ, Kohane IS. Mutual information relevance networks: functional genomic clustering using pairwise entropy measurements. *Pacific Symposium on Biocomputing*. 2000;5:418–429.
6. Szklarczyk D, et al. The STRING database in 2023: protein–protein association networks and functional enrichment analyses. *Nucleic Acids Research*. 2023;51(D1):D638–D646. doi:10.1093/nar/gkac1000.